

A photograph of two surgeons in an operating room. They are both wearing blue scrubs, blue bouffant caps, and light blue surgical masks. The male surgeon on the left is pointing at a clipboard held by the female surgeon on the right. They are both looking down at the clipboard. In the background, there are surgical lights, a monitor displaying vital signs, and other medical equipment. The overall tone is professional and clinical.

Predicción de Riesgo Anestésico elevado mediante Machine Learning

Entrenamiento y optimización de modelos de clasificación

Daniela Porticella

Coderhouse · Data Science II · Comisión 77780

Tutora: Erica Destefano | Abril 2026



Objetivo y problema



Pregunta principal

¿Es posible predecir si un paciente tendrá riesgo anestésico elevado (ASA III–IV) a partir de sus variables clínicas preoperatorias?



Tipo de problema

Clasificación binaria
Clase 0: Riesgo bajo (ASA I–II)
Clase 1: Riesgo alto (ASA III–IV)



¿Por qué importa?

Identificar tempranamente pacientes de mayor riesgo permite priorizar recursos, adelantar interconsultas y mejorar la planificación quirúrgica.

Dataset y preparación de datos

121

registros reales

879

registros sintéticos

37

features finales

Preparación

- Anonimización: eliminación de identificadores personales
- Nulos en comorbilidades → False (ausencia = no registrada)
- Variable derivada: BMI calculado desde peso y altura
- Variable objetivo binaria: asa_risk (0 = bajo, 1 = alto)
- Exclusión de height y weight (redundantes con BMI)
- Variable nueva: comorbidity_count (suma de comorbilidades)

Modelos entrenados



Regresión Logística

- Modelo lineal de clasificación
- Busca la combinación de variables que mejor separa los dos grupos
- Simple e interpretable — cada variable tiene un coeficiente auditable
- AUC-ROC (CV 5-fold): 0.988 ± 0.003
- Recall alto riesgo (test): 0.92



Random Forest

- Ensamble de múltiples árboles de decisión
- Captura relaciones no lineales entre variables
- Optimizado con GridSearchCV (24 combinaciones)
- AUC-ROC (CV 5-fold): 1.000
- Mejores params: max_depth=None, n_estimators=100

Comparación de performance

Modelo	Accuracy	Precision	Recall	F1	AUC-ROC
Regresión Logística	0.960	0.988	0.920	0.953	0.986
Random Forest	1.000	1.000	1.000	1.000	1.000
Random Forest Optimizado ✓	1.000	1.000	1.000	1.000	1.000

⚠ Sobre los resultados perfectos

Los valores de AUC 1.000 reflejan overfitting por datos sintéticos, no performance real. El 88% del dataset son copias del original. Con datos reales se esperaría AUC entre 0.75 y 0.85.

💡 **La Regresión Logística, con Recall = 0.92 y AUC = 0.986, ofrece resultados más honestos e interpretables clínicamente.**

Simulación clínica – 5 casos reales

Se ingresaron 5 casos ficticios al modelo Random Forest optimizado y se comparó con el criterio clínico experto.

1	M, 71a, HTA, urológica, CF >4 METs	ASA II	Bajo 27%	✓
2	M, 53a, obesidad, DM, HTA, tabaco, urológica	ASA III	Bajo 32%	✗
3	F, 38a, sin comorbilidades, ginecológica	ASA II	Bajo 2%	✓
4	M, 64a, HTA, valvulopatía, gastro, CF no eval.	ASA III/IV	Alto 76%	✓
5	F, 86a, HTA, ginecológica, CF >4 METs	ASA II	Bajo 20%	✓

4 de 5 casos correctos | Error en caso 2: perfil subrepresentado en el dataset original

Conclusión

✓ Modelo seleccionado: Random Forest optimizado (AUC 1.000). Con datos reales, la Regresión Logística ofrece mayor interpretabilidad clínica.

✓ Variables más predictivas: edad, capacidad funcional y carga de comorbilidades — consistente con el juicio clínico.

⚠ Overfitting por datos sintéticos: métricas perfectas no reflejan generalización real. El modelo memoriza, no aprende.

⚠ Limitación del dataset: solo 121 registros reales. Perfiles poco frecuentes quedan subrepresentados.

"Un modelo es tan bueno como los datos con los que fue entrenado."